

Data Lakes

MLOPs II - UBA

Jaime Andrés Riascos-Salas

2026

¿Cuáles son los mayores desafíos
con los datos hoy en día?


=

Los mayores desafíos con los datos en la actualidad

- Calidad de los datos
- Obsolescencia
- Volumen de datos
- Escala
- Costos



Realidades:

- El 60% informó que la calidad de los datos era el principal desafío.
- El 86% de los analistas tuvo que usar datos obsoletos, y el 41% usó datos que tienen > de 2 meses de antigüedad.
- El 90% tuvo regularmente fuentes de datos poco confiables en los últimos 12 meses




Proceso tradicional business analytics


1. Comience con los requisitos del usuario final para identificar los informes y análisis deseados
2. Definir el esquema y las consultas de la base de datos correspondientes
3. Identificar las fuentes de datos necesarias
4. Creación de una canalización de extracción-transformación-carga (ETL) para extraer datos necesarios (curación) y transformarlos en esquema de destino ("esquema en escritura")
5. Crear informes. Análisis de datos




Dos enfoques para obtener valor de los datos: Top-Down + Bottoms-Up



Data Warehouses utiliza un Approach Top-Down



Data Lakes usa un enfoque Bottom-Up




Data Lake + Data Warehouse Mejor juntos!

¿Qué pasó?

Descriptive
Analytics

¿Por qué sucedió?

Diagnostic
Analytics



¿Qué pasará?


Predictive
Analytics

¿Cómo podemos hacer que
suceda?

Prescriptive
Analytics

Enfoques tradicionales

Estado actual de un data warehouse



Bien cuidado, a menudo fuentes relacionales

Volumen y formatos de datos conocidos y esperados

Poco o ningún cambio



Transformaciones complejas y rígidas

Supervisión exhaustiva requerida

Estructuras históricas transformadas en lecturas




Acceso plano, encapsulado o multidimensional a datos históricos

Muchos informes, múltiples versiones de la "verdad"

Retraso de 24 a 48 horas

Enfoques tradicionales

Estado actual de un data warehouse



Aumento de la variedad de fuentes de datos

Aumento del volumen de datos

Aumento de los tipos de datos

Presión sobre el motor de ingesta

Las transformaciones complejas y rígidas ya no pueden seguir el ritmo

Se abandona el monitoreo

Retraso en los datos, incapacidad para transformar volúmenes o reaccionar a nuevas fuentes

Reparar, ajustar y rediseñar ETL


Los informes se vuelven inválidos o inutilizables

Aumenta el retraso en los informes conservados

Los usuarios comienzan a "innovar" para aliviar el "hambre"

Nuevos enfoques

Data Lake Transformation (ELT not ETL)



Se consideran todas las fuentes de datos

Aprovecha el poder de las tecnologías locales y la nube para el almacenamiento y la captura

Formatos nativos, datos de streaming, big data



Extracción y carga, transformación mínima o nula

Almacenamiento de datos en formato casi nativo

La orquestación se hace posible

La adaptación de datos de transmisión se vuelve posible




Las refinerías transforman los datos en lectura

Produce conjuntos de datos seleccionados para integrarlos con los almacenes tradicionales

Los usuarios descubren conjuntos de datos/servicios publicados utilizando herramientas conocidas

Un camino largo...



Data Warehouse (1980)

- ETL (extracción, transformación, carga) directamente desde los sistemas de bases de datos operativos.
- Diseñado específicamente para análisis SQL y BI: esquemas, índices, almacenamiento en caché, etc.
- Potentes funciones de gestión como transacciones ACID y viajes en el tiempo




Data Warehouse - Problemas (2010s)

- No se podían admitir datos no estructurados y semiestructurados de rápido crecimiento: series temporales, registros, imágenes, documentos, etc.
- Alto costo para almacenar grandes conjuntos de datos.
- No hay soporte para ciencia de datos y ML




Data Lakes (2010s)

- Almacenamiento de bajo costo para almacenar todos los datos sin procesar, por ejemplo, Amazon S3 y HDFS.
- Los trabajos ETL luego cargan datos específicos en almacenes, posiblemente para ELT adicional.
- Se puede leer directamente en bibliotecas de ML (por ejemplo, TensorFlow y PyTorch) debido al formato de archivo abierto.



Data Lakes – Problemas (2010s)

- Es barato almacenar todos los datos, ¡pero la arquitectura del sistema es mucho más compleja!
- La fiabilidad de los datos se ve afectada:
 - Múltiples sistemas de almacenamiento con diferentes semánticas, dialectos SQL, etc.
 - Pasos adicionales de ETL que pueden salir mal.
- La puntualidad y el alto costo de procesamiento:
 - Pasos adicionales de ETL antes de que los datos estén disponibles en los almacenes de datos.
 - ETL continuo, almacenamiento duplicado.



Data Lakes vs Data Warehouse

- Data Lake almacena todos los datos independientemente de la fuente y su estructura, mientras que Data Warehouse almacena datos en métricas cuantitativas con sus atributos.
- Data Lake define el esquema después de almacenar los datos, mientras que Data Warehouse define el esquema antes de almacenar los datos.
- Data Lake usa el proceso ELT, mientras que el almacenamiento de datos usa el proceso ETL.

Data Lake

Staging & preparation

- Orientada a Científicos de datos/usuarios avanzados
- Procesamiento por lotes
- Refinamiento/limpieza de datos
- Cargas de trabajo de ETL
- Almacenar datos más antiguos/de copia de seguridad
- Sandbox para exploración de datos
- Informes únicos
- Acceso rápido a los datos
- Preguntas desconocidas

Data Warehouse

Serving, Security & Compliance


- Orientada a usuarios alto nivel
- Baja latencia
- Uniones complejas
- Consulta ad-hoc interactiva
- Alto número de usuarios
- Seguridad adicional
- Gran soporte para herramientas
- Paneles
- Cree informes fácilmente (BI de autoservicio)
- Conoce las preguntas

Lakehouse

Unica plataforma para todos los usos

Organización de las características (transacciones, versionado, etc)


Data Lakes para almacenar todos los tipos de datos



Los sistemas Lakehouse combinan los beneficios de los almacenes de datos y los lagos de datos al tiempo que simplifican las arquitecturas de datos empresariales

Lakehouse

Implementar la gestión de almacenes de datos y funciones de rendimiento además de las de acceso directo datos en formatos abiertos.



Last updated: Sept 1, 2019


- ✓ Exact copy of source data in native format (aka master dataset in the batch layer)
- ✓ Immutable to change
- ✓ History retained indefinitely
- ✓ Data access is highly limited to few people
- ✓ Everything downstream can be regenerated from raw

- ✓ Selectively utilized
- ✓ Separation of "new data" from "raw data" to ensure data consistency
- ✓ Transient low-latency data (aka speed layer)
- ✓ Data quality validations

- ✓ Reference data

- ✓ Manually generated data

- ✓ Data staged for a specific purpose or application



Coates Data Strategies 

- ✓ Raw data which varies in format or schema, such as JSON which is standardized into columns & rows (aka "semantic normalization")
- ✓ File consolidations of data (i.e., to overcome performance issues with many small files)

- ✓ Active archive of aged data, available for querying when needed

- ✓ Workspace for exploratory data science & analytics
- ✓ Valuable efforts are productionized to the curated data zone

- ✓ Cleansed and transformed data, organized for optimal data delivery (aka serving layer)
- ✓ Supports self-service
- ✓ Standard security, change management, and governance

Cloud data lakes

La migración desde sistemas locales (*on-premise*) a la nube **elimina altos costos** de infraestructura y mantenimiento, permitiendo enfocarse en extraer el máximo valor de los datos.

Una evolución del *data warehouse* tradicional, diseñados para ofrecer mayor **escalabilidad, velocidad y rentabilidad**.

Para gestionar grandes y variados volúmenes de datos, impulsando iniciativas clave como **Inteligencia Artificial, Machine Learning y Business Intelligence**.

•**Desafío Actual:** Seleccionar el proveedor de nube adecuado (desde vendedores tradicionales hasta las nuevas arquitecturas *lakehouse*) es crucial para el éxito del proyecto.

Cloud data lakes

Limitaciones de los lagos locales

- Elasticidad
- Falta de seguridad y gobernanza
- Altos costos de mantenimiento

Ventajas de los lagos basados en la nube

- Almacenamiento y computación desacoplados
- Seguridad y cifrado integrados
- Escalado transparente
- Infraestructura flexible bajo demanda
- Precios basados en el consumo

Cómo funciona la integración con Data Lakes

Conectividad con las fuentes: Los datos provienen de múltiples sistemas, bases de datos, CRM, ERP, API, dispositivos IoT, registros o servicios de terceros. Estos sistemas utilizan conectores o agentes de datos para exportar datos al lago de datos.

Canalizaciones de ETL/ELT: las herramientas de integración (como Azure Data Factory, AWS Glue o Google Cloud Dataflow) se usan para extraer, transformar y cargar (ETL) o extraer, cargar y transformar (ELT) datos en el lago. Estas canalizaciones se pueden programar o activar en tiempo real.

Formatos de datos: se utilizan formatos de datos comunes como JSON, Parquet, Avro, ORC y CSV para garantizar la compatibilidad y optimizar el rendimiento. Estos formatos son especialmente adecuados para la eficiencia del análisis y el almacenamiento.

API y SDK: los lagos de datos en la nube admiten API RESTful, SDK e integraciones prediseñadas para facilitar que las aplicaciones, las herramientas de BI o las plataformas de datos interactúen con el lago de datos.

Catálogos de datos e integración de metadatos: la integración con servicios de metadatos o catálogos de datos (por ejemplo, AWS Glue Data Catalog, Azure Purview o GCP Data Catalog) garantiza la capacidad de detección, la gobernanza y el seguimiento del linaje.

Seguridad y controles de acceso: La integración segura implica autenticación, políticas de acceso, cifrado en reposo y en tránsito, y cumplimiento de las políticas de gobernanza de datos.

Consumo: una vez integrado, el lago de datos sirve como centro para sistemas descendentes como almacenes de datos, modelos de aprendizaje automático, paneles y aplicaciones en tiempo real para consumir conjuntos de datos enriquecidos y seleccionados.

Top 7 Data Lake Cloud solutions

1. Apache Hadoop
2. Apache Spark
3. Databricks
4. AWS
5. Azure
6. Google Cloud
7. Snowflake

CLOUD DATABASES



**Cloud
Agnostic**



Relational

Traditional applications, enterprise resource planning (ERP), customer relationship management (CRM), ecommerce



SQL Database



Key-Value

High-traffic web applications, ecommerce systems, gaming applications



Cosmos DB



In-memory

Caching, session management, gaming leaderboards, geospatial applications



Cache for Redis



Document

Content management, catalogs, user profiles



Cosmos DB



Wide column

High-scale industrial apps for equipment maintenance, fleet management, and route optimization



Cosmos DB



Graph

Fraud detection, social networking, recommendation engines



Cosmos DB



Time series

Internet of Things (IoT) applications, DevOps, industrial I telemetry



Cosmos DB



Cloud Spanner



Cloud SQL



Cloud Bigtable



Memorystore



Firestore



Cloud Bigtable



Cloud Bigtable



JanusGraph



Cloud Bigtable



BigQuery



Amazon RedShift



Amazon RDS



Amazon Aurora



Amazon DynamoDB



Amazon MemoryDB



Amazon ElastiCache



Amazon DocumentDB



Amazon Keyspaces



Amazon Neptune



Amazon Timestream



SQL Server



Oracle



DB2



MySQL



PostgreSQL



Redis



Scylla DB



Ignite



Redis



Memcached



Hazelcast



Ignite



MongoDB



Couchbase



Solr



HBase



Cassandra



Scylla DB



OrientDB



Neo4J



Giraph



OpenTSDB



InfluxDB



Scylla DB

AWS Data Lake

AWS ofrece un ecosistema completo para crear *data lakes* seguros y rentables.

- **Almacenamiento Central:**
 - **Amazon S3:** La base para todo tipo de datos.
 - **DynamoDB:** (Opcional) Para datos de baja latencia como IoT o *clickstream*.
- **Procesamiento de Datos:**
 - **Amazon EMR:** Motor que automatiza el procesamiento (*batch* y *streaming*) usando herramientas de código abierto como **Spark** y **Hive**.
- **Ingesta y Migración:**
 - Servicios como **Kinesis** y **DMS** para mover datos hacia S3 desde cualquier fuente (local o en la nube).
- **Análisis y Consulta:**
 - Herramientas gestionadas como **Athena** para consultas interactivas y **Elasticsearch** para análisis de logs.

Azure Data Lake

Una plataforma integral para almacenamiento, procesamiento y análisis de datos a gran escala.

- **Almacenamiento Unificado:**
 - **Azure Data Lake Storage (ADLS) Gen2:** La base del sistema. Combina lo mejor de un sistema de archivos y el almacenamiento de objetos (*BLOB*) para un rendimiento y costo optimizados.
- **Motores de Análisis Flexibles:**
 - **HDInsight:** Servicio gestionado para herramientas de código abierto (ej. Hadoop).
 - **Data Lake Analytics:** Plataforma bajo demanda para código personalizado (Python, R, .NET).
- **La Estrategia Unificada: Azure Synapse Analytics:**
 - Es la solución de arquitectura "**Lakehouse**" de Microsoft, que integra *data lake* y *data warehouse*.
 - Combina **motores SQL y Apache Spark** en una sola plataforma para simplificar el procesamiento y análisis de datos.
- **Seguridad y Gobernanza:**
 - Integración nativa con **Azure Active Directory** para control de acceso basado en roles (RBAC) e inicio de sesión único (SSO).

Google Data Lake

Una plataforma integrada para gestionar y analizar datos a gran escala de forma segura y rentable.

- **Almacenamiento Central:**
 - **Google Cloud Storage (GCS):** La base del *data lake*, ofreciendo un almacenamiento de bajo costo y propósito general.
- **Procesamiento y Análisis:**
 - **Dataproc:** Servicio gestionado para el ecosistema de código abierto (ej. **Apache Spark** y **Hive**).
 - **Dataflow:** Procesamiento *serverless* unificado para datos en tiempo real (*streaming*) y por lotes (*batch*).
- **Funcionalidad "Lakehouse" con BigQuery:**
 - **Google BigQuery:** El *data warehouse serverless* de Google puede **consultar datos directamente sobre GCS**, unificando el *data lake* con capacidades analíticas avanzadas.
- **Herramientas Integradas:**
 - **Ingesta:** Con **Pub/Sub** y **Transfer Services**.
 - **Exploración y ML:** Con **Cloud Datalab**.

CRITERIA	aws	Microsoft Azure	Google Cloud Platform
Primary Storage Service	Amazon S3	ADLS Gen 2	Google Cloud Storage
Processing Engine	Amazon EMR	Azure HDInsight, Azure Synapse	Google Dataproc, Data Flow
Hive and Spark Support	Yes	Yes	Yes
Decoupled Storage & Compute	Yes	Yes	Yes
Pipeline Service	AWS Glue	Azure Data Factory	Cloud Data Fusion, Data Flow
SQL Support	Amazon Athena, Redshift, Spectrum	Azure Synapse	Google BigQuery
Support for Multiple Programming Languages	Yes	Yes	Yes
Catalog	AWS Glue	Azure Data Catalog	Google Data Catalog
Lakehouse Architecture	Yes	Yes	Yes
Multi-Cloud	No	No	No

Descripción general de un pipeline de Big Data

Las canalizaciones de big data en plataformas en la nube suelen seguir un flujo estructurado:

Ingesta: captura y transmisión de datos de varios orígenes.

Data Lake Storage: almacenamiento de datos sin procesar y procesados para su posterior transformación.

Preparación y computación: procesamiento, limpieza y transformación de datos mediante análisis y aprendizaje automático.

Almacén de datos: almacenamiento de datos estructurados optimizados para consultas e informes.

Presentación: visualización de datos para obtener información y tomar decisiones.

Ingesta de datos

AWS:

- AWS IoT y Kinesis Streams/Firehose gestionan la ingesta de datos en tiempo real.
- Las funciones de Lambda procesan los eventos entrantes.
- S3 proporciona almacenamiento en la nube, con Glacier para el almacenamiento de archivos a largo plazo.

Azure:

- Azure IoT Hub y Event Hub admiten la ingesta de datos de gran volumen.
- Azure Functions permite el procesamiento controlado por eventos sin servidor.
- Azure Data Lake Store captura datos sin procesar para su posterior transformación.

GCP:

- Cloud IoT Core y Pub/Sub sirven como componentes de transferencia en tiempo real de GCP.
- Cloud Functions maneja el procesamiento basado en eventos.
- Cloud Storage actúa como el lago de datos para los archivos sin procesar.

Comparación: AWS y Azure tienen capacidades de IoT más sólidas, mientras que GCP sobresale en el procesamiento basado en eventos sin problemas con Pub/Sub.

Almacenamiento de Data Lake

AWS:

- Amazon S3 es el servicio de almacenamiento principal para lagos de datos, con opciones de administración del ciclo de vida y almacenamiento en niveles.

Azure:

- Azure Data Lake Store admite el almacenamiento a gran escala con controles de gobernanza y seguridad empresarial.

GCP:

- Cloud Storage sirve como base para las soluciones de lago de datos de Google.

Comparación: AWS S3 lidera en versatilidad, mientras que Azure Data Lake Store está diseñado para cargas de trabajo a escala empresarial con controles de seguridad superiores. Cloud Storage de GCP es rentable y se integra perfectamente con otros servicios.

Preparación y Computación de Datos

AWS:

- AWS Glue proporciona capacidades de ETL.
- Kinesis Analytics admite el procesamiento de transmisiones en tiempo real.
- EMR (Elastic MapReduce) permite el procesamiento a gran escala con Spark y Hadoop.
- SageMaker ofrece entrenamiento e implementación de modelos de aprendizaje automático (ML).

Azure:

- Azure Databricks impulsa la ingeniería de datos distribuida y las cargas de trabajo de ML.
- Stream Analytics procesa datos de streaming en tiempo real.
- Azure ML proporciona funcionalidades de inteligencia artificial y aprendizaje automático.

GCP:

- DataProc ejecuta clústeres de Hadoop y Spark.
- DataFlow proporciona procesamiento por lotes y flujos sin servidor.
- AutoML simplifica el entrenamiento del modelo de ML.

Comparación: AWS Glue y EMR sobresalen en ingeniería de datos escalable, Azure Databricks ofrece una integración profunda de ML y AutoML de GCP hace que ML sea accesible para un público más amplio.

Data Warehousing

AWS:

- RedShift es el almacén de datos completamente administrado de AWS.
- RDS y DynamoDB proporcionan soluciones de bases de datos estructuradas y NoSQL.
- Glue Catalog mantiene metadatos para la gobernanza de datos.

Azure:

- Azure SQL y Cosmos DB ofrecen soluciones de bases de datos relacionales y NoSQL.
- Azure Redis Cache mejora el rendimiento de las aplicaciones en tiempo real.

GCP:

- BigQuery es el almacén de datos sin servidor de Google para consultas de alta velocidad.
- Bigtable y Cloud Datastore admiten cargas de trabajo NoSQL.
- MemoryStore mejora el almacenamiento en caché de datos en memoria.

Comparación: AWS RedShift es la opción para el almacenamiento tradicional, Azure SQL ofrece un sólido soporte empresarial y GCP BigQuery supera el rendimiento en análisis sin servidor y de pago por uso.

Presentación y visualización

AWS:

- Athena permite la consulta de datos de S3 mediante SQL.
- QuickSight proporciona paneles de inteligencia empresarial (BI).
- Las funciones de Lambda desencadenan la entrega de información.




Azure:

- Power BI es la poderosa herramienta de visualización de BI de Microsoft.
- Azure ML Designer admite el análisis exploratorio de datos (EDA).

GCP:

- Colab (EDA) permite el análisis interactivo.
- Data Studio proporciona paneles e informes.
- Cloud Functions automatiza los flujos de trabajo.

Comparación: Power BI lidera en informes empresariales, QuickSight se integra bien con AWS y Data Studio ofrece una solución de informes gratuita y flexible.



Elegir la plataforma adecuada


Cada proveedor de nube sobresale en diferentes áreas:

AWS es más adecuado para empresas que requieren procesamiento de big data escalable e integrado y análisis basados en IA.

Azure es ideal para las empresas que aprovechan el ecosistema de Microsoft y una sólida gobernanza empresarial.


GCP es la mejor opción para el análisis en tiempo real y el procesamiento de datos rentable y sin servidor.

En última instancia, la mejor plataforma depende de las necesidades de su organización, la infraestructura existente y la estrategia de datos. Comprender los componentes de la canalización de big data de cada proveedor ayuda a tomar una decisión informada, optimizar el rendimiento y garantizar operaciones de datos sin problemas.


Element	aws	Google Cloud Platform		ORACLE®	Open source / 3rd Party
Data Collection	 Cloud Watch  Cloud Watch Logs  Cloud Trail  Config  Custom agents / Scripts	 Cloud Monitoring  Cloud Logging  Cloud Audit Logs  Custom agents / Scripts	 Azure Monitor  Azure Activity Log  Azure Policy  Security Center  Custom agents / Scripts	 Pulse  Health Checks  Monitoring Free  Oracle Management Cloud  Security Zones	         
Data Storage	 S3	 Cloud Storage	 Blob Storage	 File Storage	  
Data Analysis	 CloudWatch Metrics Insights	 Cloud Operations	 Azure Monitor Metrics Explorer	 Audit  Logging	  
Alerting	 SNS	 Cloud Monitoring Alerts	 Azure Monitor Alerts		 
Visualization	 CloudWatch Dashboard  QuickSight	 Cloud Monitoring Dashboard  Data Studio	 Azure Monitor Dashboard  Power BI		    
Reporting and Compliance	 Config Rules  Trusted Advisor	 Security Command Center	 Policy Compliance  Security center Compliance	 Compliance Documents	 
Automation	 Lambda  Step Functions	 Cloud Functions	 Azure Functions  Azure Automation	 OCI Functions	 
Integration	 CloudFormation  CodePipeline	 Cloud Deployment Manager  Cloud Build	 Azure Automation  Azure Dev Ops	 Resource Manager	     
Feedback Loop	 Well-Architected Tool	 Well-Architected Framework	 Well-Architected Framework	 Oracle Cloud Infrastructure Architecture Center	 

Lakehouse con AWS

- AWS S3 como el lago de datos para almacenar todas las formas de datos.
- AWS Lake Formation es útil para crear lagos de datos seguros y administrados en un corto período de tiempo.
- Las transformaciones basadas en Spark se pueden realizar mediante EMR o Glue.
- No se realizan transformaciones basadas en código/flujo de trabajo con Glue Data Studio/Glue Databrew. También se pueden utilizar herramientas de terceros como DBT.




Lakehouse con Azure




- Las transformaciones basadas en Spark se pueden realizar mediante Azure Databricks.
- Azure Synapse admite varias opciones de transformación mediante grupos de Data Explorer/Spark/Serverless.
- También se pueden utilizar herramientas de terceros como Fivetran para mover datos. Las herramientas de terceros como Fivetran también son una opción.

Lakehouse usando GCP



- Las transformaciones basadas en Spark se pueden realizar con Dataproc.
- No se realizan transformaciones basadas en código o flujo de trabajo mediante DataFlow. También se pueden utilizar herramientas de terceros como DBT.

Lakehouse usando Snowflake:



- La implementación de un lakehouse en Snowflake es bastante única, ya que la plataforma en la nube subyacente podría ser cualquiera de las 3 grandes (AWS, Azure, GCP), y Snowflake puede ejecutarse sobre ella.
- Los servicios de migración nativos de la nube se pueden utilizar para almacenar los datos en el almacenamiento en la nube respectivo.
- También se pueden utilizar herramientas de terceros como Airbyte y Fivetran para ingerir los datos.
- Las tablas de diccionario se pueden usar para catalogar los archivos almacenados provisionalmente en el almacenamiento en la nube.
- Las transformaciones basadas en Spark se pueden realizar mediante Snowpark con soporte para Python.

